
Восстановление функциональных групп головного мозга с помощью графовых диффузных моделей

Касюк Вадим
kasiuk.va@phystech.edu

Игнатьев Даниил
ignatev.da@phystech.edu

Панченко Святослав
panchenko.sk@phystech.edu

Abstract

Рассматривается задача классификации активности человека по сигналам электроэнцефалограммы его головного мозга. Классические подходы, основанные на свёрточных сетях, не учитывают пространственную структуру сигнала, регистрируемого датчиками, и неизбежно теряют информацию. Предлагается осуществить классификацию сигналов мозга на основе графовых представлений его функциональных групп, а в качестве предсказательной модели использовать графовую нейронную диффузию GRAND и BLEND. Полученные результаты показывают, что предлагаемое решение превосходит в качестве существующие аналоги.

Ключевые слова Головной мозг, ЭЭГ, нейронные сети, диффузионные модели

1 Введение

Целью исследования является построение функциональных групп головного мозга с помощью современных графовых диффузионных моделей[1]. На основании анализа полученных результатов предполагается доказать интерпретируемость ЭЭГ исследований для разных людей, что позволит экспертам в области нейробиологии разрабатывать более эффективные методы лечения патологий головного мозга[2].

Объектом исследования являются пространственные временные ряды полученные с помощью ЭЭГ головного мозга группы испытуемых. Устройство для считывания сигнала представляет собой набор датчиков – электродов, расположенных на поверхности кожи головы по одной из общепринятых систем размещения. На выходе получается меняющаяся во времени с определенной частотой дискретизации матрица с значениями интенсивности датчиков в ее ячейках.

Проблематика данной задачи заключается в том, что предыдущие исследования [3, 4, 5] не учитывают пространственную структуру сигнала, что не позволяет добиться высокой точности. Более того, даже те модели[3, 6, 7], которые пытаются учесть эту особенность, не учитывают динамическую зависимость этих групп, что так же ограничивает точность результатов.

Автор статьи ставит перед собой задачи : 1) Повторить эксперименты Святослава Панченко 2) Провести эксперимент используя графовую нейронную диффузию GRAND[8] и BLEND[9]. 3) Провести сравнительный анализ с предыдущими решениями

2 Постановка задачи

Дана выборка $\mathcal{D} = (\underline{\mathbf{X}}, \mathbf{Z}, \mathbf{y})$ активности головного мозга, где

$\underline{\mathbf{X}} = [\mathbf{X}_m]_{m=1}^M$ – набор сигналов,

$\mathbf{X}_m = [\mathbf{x}_t]_{t \in T}$ – сигнал, полученный в m -ом испытании,

$\mathbf{x}_t \in \mathbb{R}^E$ – наблюдения сигнала в момент времени t ,

$\mathbf{Z} = [\mathbf{z}_k]_{k=1}^E z_k \in \mathbf{R}^3$ – координаты электродов,

$\mathbf{y} = [y_m]_{m=1}^M$ – целевая переменная,

$y_m \in 1, \dots, C$ – метка класса,

$T = \{t_n\}_{n=1}^N$ – набор временных отсчетов,

$E = 62$ – число электродов,

N – число наблюдений в одном отрезке сигнала.

По выборке \mathcal{D} строится неориентированный динамический граф: $\mathcal{G}(m, t) = (\mathcal{V}(m, t), \mathcal{E}(m, t), \mathbf{A}_{\mathbf{X}, \mathbf{Z}}(m, t))$, где

$\mathcal{V}(m, t)$ – множество электродов,

$\mathcal{E}(m, t)$ – множество ребер,

$\mathbf{A}_{\mathbf{X}, \mathbf{Z}}(m, t)$ – матрица смежности графа, определяющая веса ребер ,

$\underline{\mathbf{A}}_{\mathbf{X}, \mathbf{Z}} = [\underline{\mathbf{A}}_{\mathbf{X}, \mathbf{Z}}]_{m=1}^M$ – набор матриц смежности.

Для решения задачи декодирования рассматривается модель из класса графовых рекуррентных нейронных сетей, параметризуемого множеством Θ :

$$h_\theta : (\underline{\mathbf{X}}, \underline{\mathbf{A}}_{\mathbf{X}, \mathbf{Z}}) \rightarrow y, \theta \in \Theta$$

В качестве функции ошибки выбрана кросс-энтропия:

$$\mathcal{L} = -\frac{1}{M} \sum_{m=1}^M \left[\sum_{c=1}^C 1(y_m = c) \log(p_m^c) \right],$$

где

$$p_m^c = h_\theta \left(\mathbf{X}_m, \underline{\mathbf{A}}_{\mathbf{X}, \mathbf{Z}}(m) \right) \text{ – вероятность класса } c$$

для \mathbf{X}_m с матрицей $\underline{\mathbf{A}}_{\mathbf{X}, \mathbf{Z}}(m)$.

Задача поиска оптимальных параметров имеет следующий вид:

$$\hat{\theta} = \arg \max_{\theta \in \Theta} \mathcal{L}(\theta, \mathbf{X}, \underline{\mathbf{A}}_{\mathbf{X}, \mathbf{Z}})$$

3 Предложенное решение

Предлагается следующий пайплайн GNN+LSTM:

1. По исходным данным \mathcal{D} строится неориентированный динамический граф $\mathcal{G}(m, t)$.
2. Граф $\mathcal{G}(m, t)$ подается на вход GNN. На выходе получаем многомерный временной ряд представлений исходных данных.
3. На выходах GNN запускаем LSTM, по его скрытому состоянию после обработки входа производим классификацию

Для построения матрицы смежности графа будем использовать методы, исследованные в [7]. Лучшие результаты были получены методом на основе корреляции Пирсона двух сигналов, поэтому будем использовать именно его. Также важным гиперпараметром является размер окна входных данных, по которому будем строить граф.

В качестве GNN предлагается использовать графовую диффузию GRAND. В основе алгоритма лежит связь с физическим уравнением диффузии:

$$\frac{\partial x(u, t)}{\partial t} = \text{div}[g(u, t, x(u, t)) \nabla_u x],$$

где $x(u, t)$ – величина потока (тепла) в среде в точке пространства u в момент времени t .

Схожим образом определяется диффузия на графе. Пусть $\mathcal{G} = (\mathcal{V} = \{1, \dots, n\}, \mathcal{E})$ неориентированный

граф с множествами вершин и ребер \mathcal{V} и \mathcal{E} соответственно. Обозначим через $\mathbf{z}_i(t) = (\mathbf{u}_i, \mathbf{x}_i) \in \mathbb{R}^d \times \mathbb{R}^{d'}$ объединенные координаты i -ой вершины. Тогда уравнение диффузии на графе имеет вид:

$$\frac{\partial \mathbf{z}_i(t)}{\partial t} = \text{div}[a(\mathbf{z}(t)) \nabla \mathbf{z}_i(t)],$$

где $a(\mathbf{z}(t))$ – диффузивность, определяет интенсивность процесса вдоль различных направлений. Найдем решение уравнения, переписав правую часть равенства, используя определения операторов дивергенции и градиента на графе и проведя дискретизацию дифференциального уравнения:

$$\frac{z_i^{(k+1)} - z_i^{(k)}}{\tau} = \sum_{j:(i,j) \in \mathcal{E}(U^{(k)})} a(z_i^{(k)}, z_j^{(k)}) (z_j^{(k)} - z_i^{(k)})$$

При $\tau = 1$ уравнение компактно переписывается в виде явной схемы Эйлера:

$$Z^{(k+1)} = (A^{(k)} - I)Z^{(k)} = Q^{(k)}Z^{(k)}$$

Решение вычисляется последовательным применением схемы несколько раз подряд. Схема GRAND обобщает многие другие подходы, в том числе может воспроизводить GCN [6], при этом использует меньше параметров, чем GCN.

4 Вычислительный эксперимент

Нами ставятся две гипотезы:

1. Утилизация пространственной информации позволит GNN показать результат лучше, чем GNN при решении задачи классификации.
2. Модель GRAND будет более робастной, чем GCN за счет меньшего количества параметров при том же качестве.

Целью эксперимента является проверить эти гипотезы.

Датасет для экспериментов: EEG Database to examine EEG correlates of genetic predisposition to alcoholism – данные ЭЭГ испытуемых из двух групп: страдающих алкоголизмом и не страдающих. Ссылка на датасет

В ходе эксперимента были обучены модели GCN для нескольких размеров окна.

Кривые обучения и значения метрик на тесте для GCN.

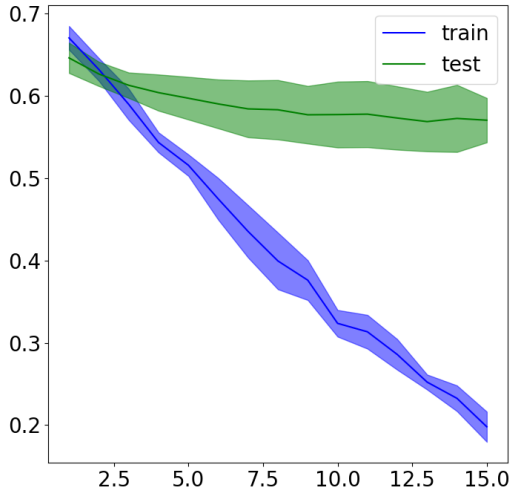


Рис. 1: Кривые обучения




Рис. 2: Значения метрик

5 Заключение

В дальнейшем планируется довести эксперимент до конца и проверить поставленные гипотезы.

Список литературы

- [1] Yue Wang, Yongbin Sun, Ziwei Liu, Sanjay E Sarma, Michael M Bronstein, and Justin M Solomon. Dynamic graph cnn for learning on point clouds. *ACM Transactions on Graphics (tog)*, 38(5):1–12, 2019.
- [2] Hedy Kober, Lisa Feldman Barrett, Josh Joseph, Eliza Bliss-Moreau, Kristen Lindquist, and Tor D Wager. Functional grouping and cortical-subcortical interactions in emotion: a meta-analysis of neuroimaging studies. *Neuroimage*, 42(2):998–1031, 2008.
- [3] Yimin Hou, Shuyue Jia, Xiangmin Lun, Ziqian Hao, Yan Shi, Yang Li, Rui Zeng, and Jinglei Lv. Gcns-net: A graph convolutional neural network approach for decoding time-resolved eeg motor imagery signals. *IEEE Transactions on Neural Networks and Learning Systems*, 2020.
- [4] Yimin Hou, Lu Zhou, Shuyue Jia, and Xiangmin Lun. A novel approach of decoding eeg four-class motor imagery tasks via scout esi and cnn. *Journal of Neural Engineering*, 2020.
- [5] Ruilin Li, Ruobin Gao, and Ponnuthurai Nagarathnam Suganthan. A decomposition-based hybrid ensemble cnn framework for driver fatigue recognition. *Information Sciences*, 2023.
- [6] Benjamin Paul Chamberlain, James Rowbottom, Davide Eynard, Francesco Di Giovanni, Dong Xiaowen, and Michael M Bronstein. Beltrami flow and neural diffusion on graphs. *Proceedings of the Thirty-fifth Conference on Neural Information Processing Systems (NeurIPS) 2021, Virtual Event*, 2021.
- [7] Вареник Н. Построение карты связности функциональных групп в задаче декодирования сигналов головного мозга. *Магистерская работа*, 2022.
- [8] Benjamin Paul Chamberlain, James Rowbottom, Maria I. Gorinova, Stefan Webb, Emanuele Rossi, and Michael M. Bronstein. GRAND: graph neural diffusion. *CoRR*, abs/2106.10934, 2021.
- [9] Benjamin Paul Chamberlain, James Rowbottom, Davide Eynard, Francesco Di Giovanni, Xiaowen Dong, and Michael M. Bronstein. Beltrami flow and neural diffusion on graphs. *CoRR*, abs/2110.09443, 2021.