

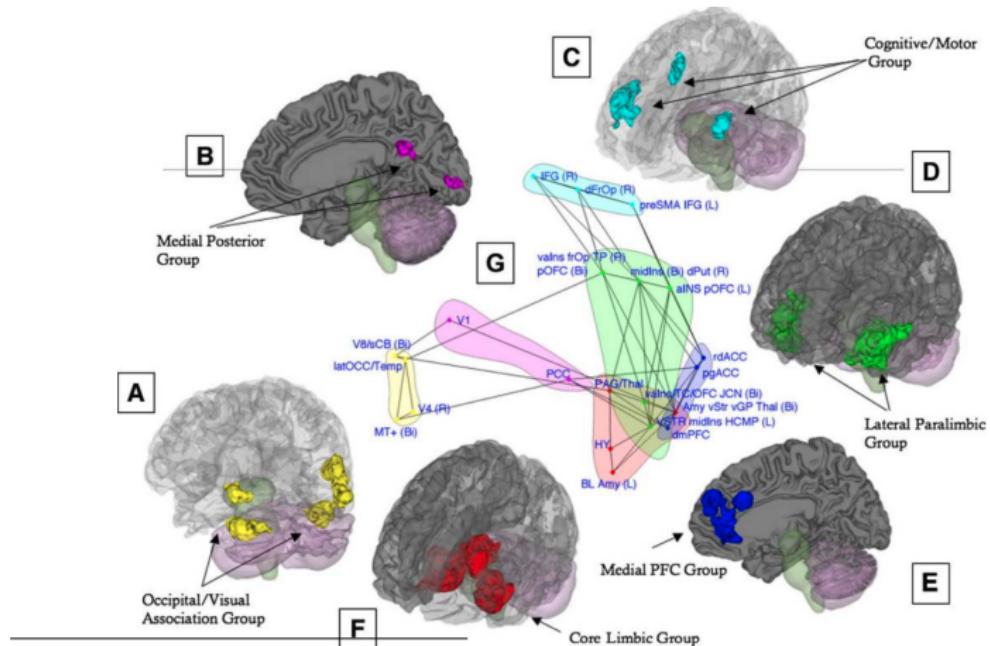
Восстановление функциональных групп головного мозга с помощью графовых диффузных моделей

Игнатьев Д.А., Касюк В.А., Панченко С.К.

Московский физико-технический институт
Москва

Москва,
2024 г.

Functional groups



Kober H. et al. Functional grouping and cortical–subcortical interactions in emotion: A meta-analysis of neuroimaging studies // Neuroimage. 2008 Aug 15; 42(2): 998–1031.

Задача: Имея данные ЭЭГ, выделить функциональные группы головного мозга. Используя найденные закономерности, решить задачу классификации.

Проблема: CNN не могут быть эффективно применены для учета пространственной информации в данных, поскольку структура сигнала на поверхности мозга нерегулярна.

Предлагается: Для учета взаимосвязей различных отделов мозга в пространстве использовать их графовые представления. Эти графовые представления использовать в качестве входных данных для *диффузионной графовой сети*.

Диффузная графовая нейросеть BLEND

Benjamin Paul Chamberlain, James Rowbottom, Davide Eynard, Francesco Di Giovanni, Xiaowen Dong, Michael M Bronstein Beltrami Flow and Neural Diffusion on Graphs

Графовые нейронные сети для задачи классификации

Вареник Н.В. Построение карты связности функциональных групп в задаче декодирования сигналов

Постановка задачи

Задан многомерный временной ряд $\underline{\mathbf{X}} = [\mathbf{X}_m]_{m=1}^M$, $\mathbf{X}_m \in \mathbb{R}^{E \times N}$ – исходный сигнал, N – число отсчетов времени, E – число электродов, M – число испытаний. Дополнительно известна матрица координат электродов $\mathbf{Z} \in \mathbb{R}^{E \times 3}$.

Задан неориентированный динамический граф:

$$\mathcal{G}(m, t) = \left(\mathcal{V}(m, t), \mathcal{E}(m, t), \mathbf{A}_{\underline{\mathbf{X}}, \mathbf{Z}}(m, t) \right),$$

в котором $\mathcal{V}(m, t)$ – множество электродов, множество ребер $\mathcal{E}(m, t)$ и их веса определяются матрицей смежности $\mathbf{A}_{\underline{\mathbf{X}}, \mathbf{Z}}(m, t)$.

Постановка задачи

Задана функция ошибок: кросс-энтропия

$$\mathcal{L} = -\frac{1}{M} \sum_{m=1}^M \left[\sum_{c=1}^C 1(y_m = c) \log(p_m^c) \right],$$

где

$$p_m^c = h_\theta \left(\mathbf{X}_m, \mathbf{A}_{\mathbf{X}, \mathbf{z}}(m, t) \right)$$

вероятность класса c для X_m с матрицей $\mathbf{A}_{\mathbf{X}, \mathbf{z}}(m)$

Требуется найти оптимальные параметры $\theta^* = \theta^*(\mathbf{X}, \mathbf{A}_{\mathbf{X}, \mathbf{z}})$ параметрического семейства функций $h(\cdot | \theta)$, минимизирующие функцию ошибки на обучающей выборке.

Уравнение диффузии

Пусть $x(u, t)$ – величина потока (тепла) в среде в точке пространства u в момент времени t . Тогда уравнение диффузии имеет вид:

$$\frac{\partial x(u, t)}{\partial t} = \operatorname{div}[g(u, t, x(u, t)) \nabla_u x]$$

Диффузия на графе

Обозначим через $\mathcal{G} = (\mathcal{V} = \{1, \dots, n\}, \mathcal{E})$ неориентированный граф с множествами вершин и ребер \mathcal{V} и \mathcal{E} соответственно.

Обозначим через $z_i(t) = (u_i, x_i)$ объединенные координаты i -ой вершины. Тогда уравнение диффузии на графе имеет вид:

$$\frac{\partial z_i(t)}{\partial t} = \operatorname{div}[a(z(t)) \nabla z_i(t)]$$

Дискретизация этого уравнения на графе имеет вид:

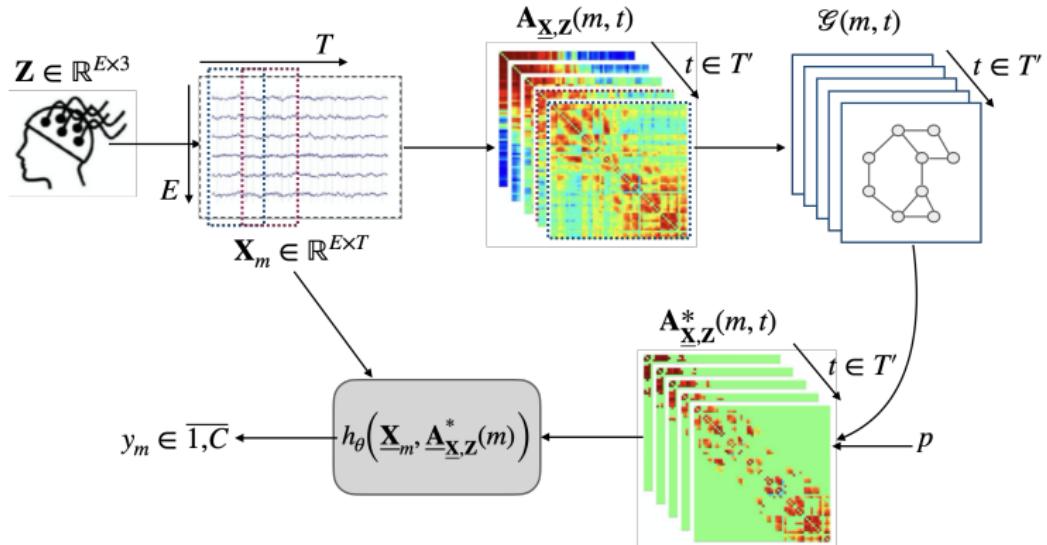
$$\frac{z_i^{(k+1)} - z_i^{(k)}}{\tau} = \sum_{j:(i,j) \in \mathcal{E}(U^{(k)})} a(z_i^{(k)}, z_j^{(k)})(z_j^{(k)} - z_i^{(k)})$$

При $\tau = 1$ уравнение компактно переписывается в виде явной схемы Эйлера:

$$Z^{(k+1)} = (A^{(k)} - I)Z^{(k)} = Q^{(k)}Z^{(k)}$$

Решение вычисляется последовательным применением схемы несколько раз подряд.

Предложенное решение



Пайплайн предложенной модели: 1) пространственная структура многомерного временного ряда описывается графом; 2) композиция графовой свёрточной сети и рекуррентной сети преобразует последовательность графовых представлений сигнала в классификационную метку.

Предложенное решение

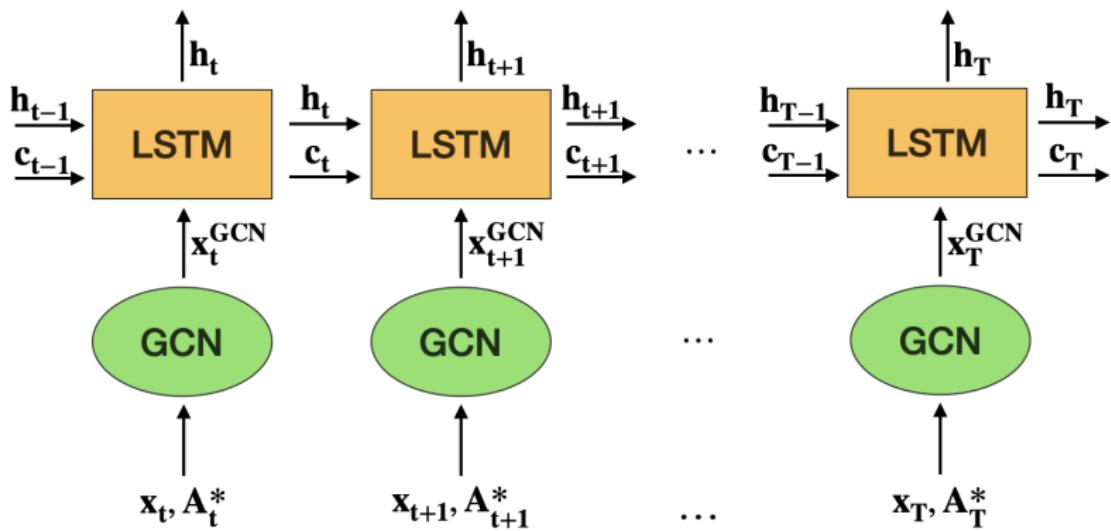


Схема использования нейросети

Гипотеза:

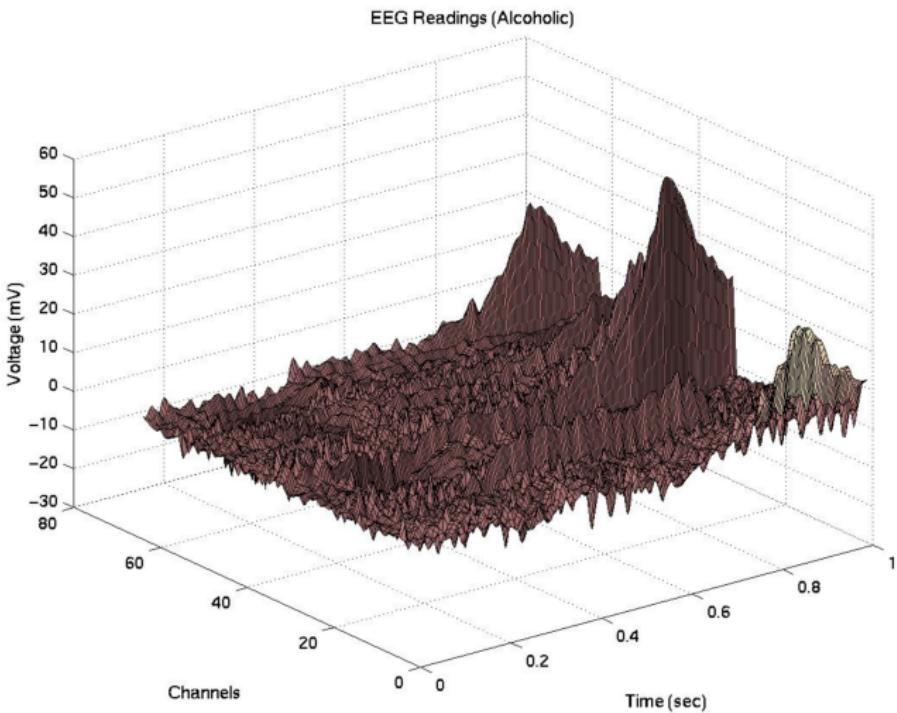
1. Использование GCN позволит улучшить качество за счет использования пространственной информации.
2. Использование графовой диффузационной сети позволит уменьшить количество параметров модели по сравнению с GCN, при этом не проигрывая в качестве

Цели:

1. Обучить BLEND и GCN для задачи классификации.
2. Сравнить качество работы полученных моделей.

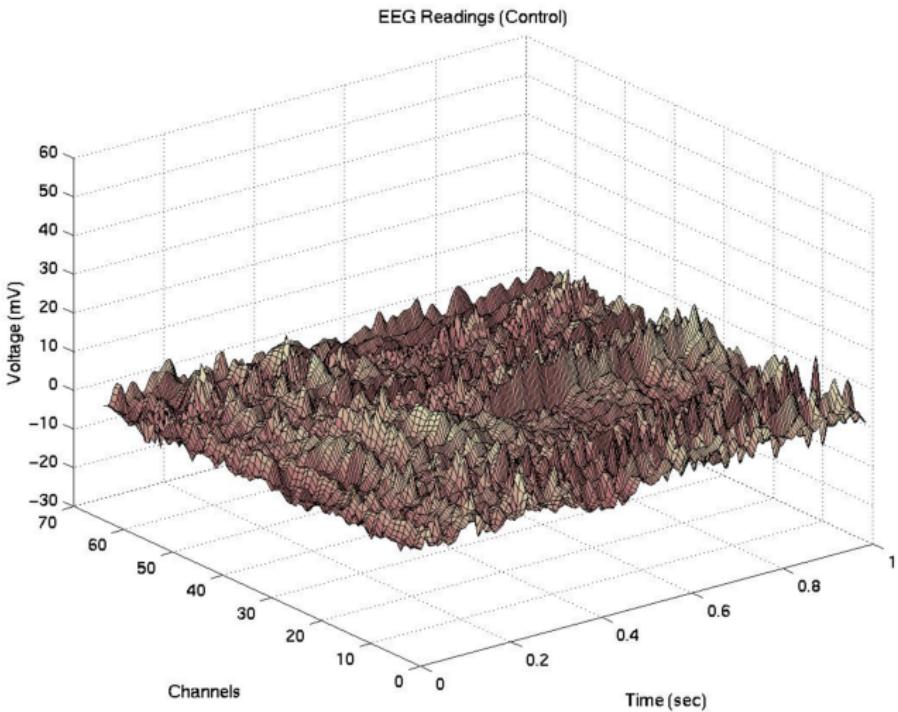
Данные: EEG Database to examine EEG correlates of genetic predisposition to alcoholism.

Вычислительный эксперимент: данные



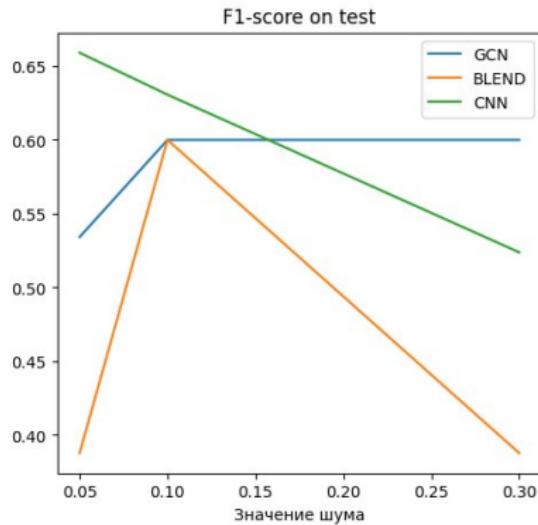
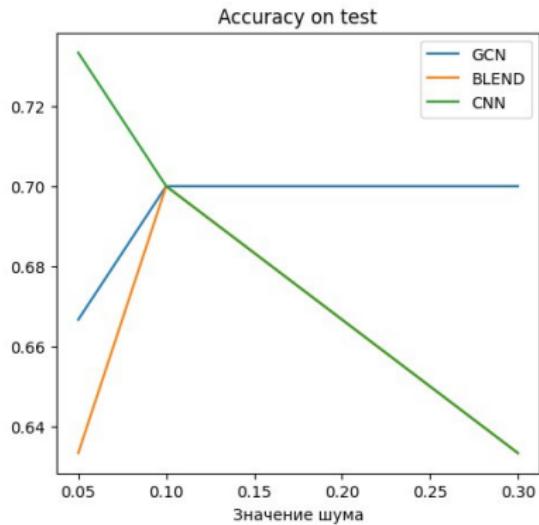
ЭЭГ испытуемого, страдающего алкоголизмом

Вычислительный эксперимент: данные

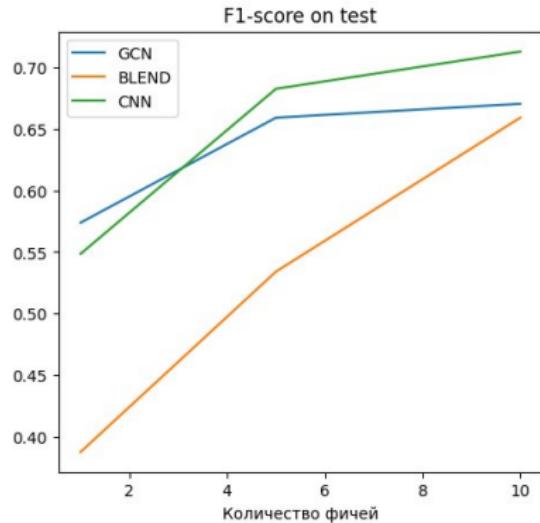
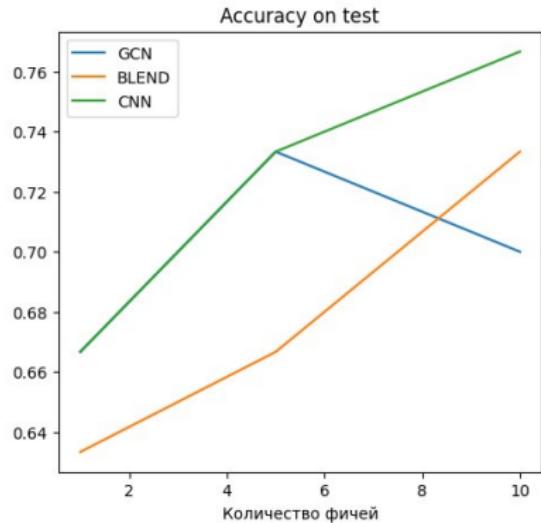


ЭЭГ испытуемого, не страдающего алкоголизмом

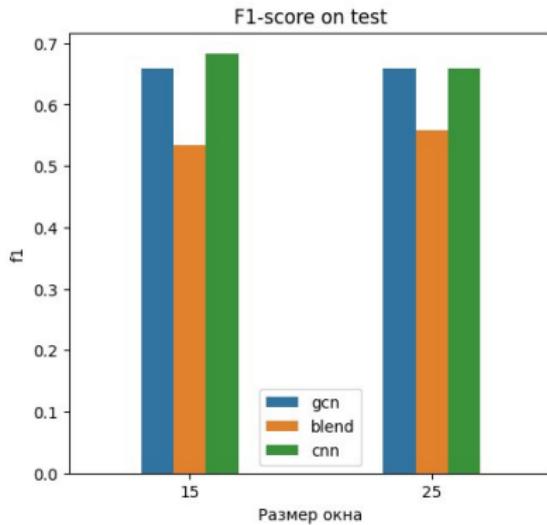
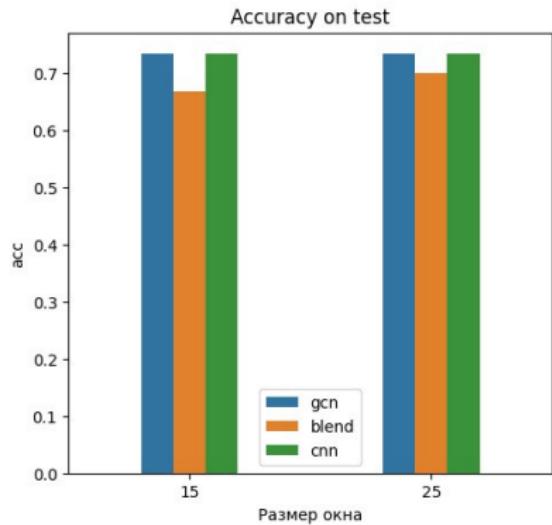
Метрики в зависимости от добавленного шума



Метрики в зависимости от размерности фичей



Метрики в зависимости от ширины окна



1. Предложена графовая диффузная нейросеть для решения задачи декодирования сигналов головного мозга.
2. Проанализирована placeholder GCN модель пространственной и функциональной структуре сигнала.
3. По результатам экспериментов не может быть подтверждена гипотеза о том, что GCN лучше справляются с декодированием сигналов, чем CNN. Вторая гипотеза может быть частично подтверждена.