

Восстановление функциональных групп головного мозга с помощью графовых диффузных моделей

Касюк В.А.

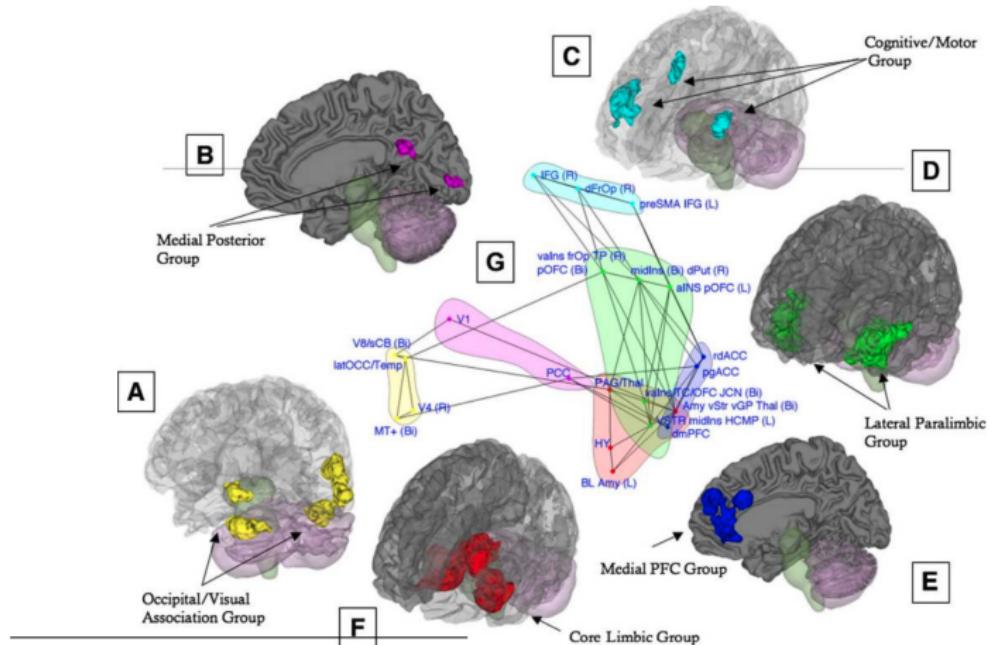
Московский физико-технический институт

Москва,
2024 г.

Целью исследования является построение функциональных групп головного мозга с помощью современных графовых диффузионных моделей. А также на основании анализа полученных результатов предполагается доказать преимущество этих моделей над сверточными и классическими.

Проблематика данной задачи заключается в том, что предыдущие исследования не учитывают пространственную структуру сигнала, что не позволяет добиться высокой точности. Более того, даже те модели, которые пытаются учесть эту особенность, не учитывают динамическую зависимость этих групп, что так же ограничивает точность результатов.

Functional groups



Kober H. et al. Functional grouping and cortical–subcortical interactions in emotion: A meta-analysis of neuroimaging studies // Neuroimage. 2008 Aug 15; 42(2): 998–1031.

Диффузная графовая нейросеть

Benjamin P. Chamberlain, James Rowbottom, Maria Gorinova, Stefan Webb, Emanuele Rossi, Michael M. Bronstein GRAND: Graph Neural Diffusion

Графовые нейросети для прогнозирования временных рядов

Andrea Cini, Ivan Marisca, Daniele Zambon, Cesare Alippi
Graph Deep Learning for Time Series Forecasting

Дополнительные ссылки

Вареник Н.В. Построение карты связности функциональных групп в задаче декодирования сигналов

Постановка задачи

Задан многомерный временной ряд $\underline{\mathbf{X}} = [\mathbf{X}_m]_{m=1}^M$, $\mathbf{X}_m \in \mathbb{R}^{E \times N}$ – исходный сигнал, N – число отсчетов времени, E – число электродов, M – число испытаний. Дополнительно известна матрица координат электродов $\mathbf{Z} \in \mathbb{R}^{E \times 3}$.

Задан ненаправленный динамический граф:

$$\mathcal{G}(m, t) = \left(\mathcal{V}(m, t), \mathcal{E}(m, t), \mathbf{A}_{\underline{\mathbf{X}}, \mathbf{Z}}(m, t) \right),$$

в котором $\mathcal{V}(m, t)$ – множество электродов, множество ребер $\mathcal{E}(m, t)$ и их веса определяются матрицей смежности $\mathbf{A}_{\underline{\mathbf{X}}, \mathbf{Z}}(m, t)$.

Постановка задачи

Задана функция ошибок: кросс-энтропия

$$\mathcal{L} = -\frac{1}{M} \sum_{m=1}^M \left[\sum_{c=1}^C 1(y_m = c) \log(p_m^c) \right],$$

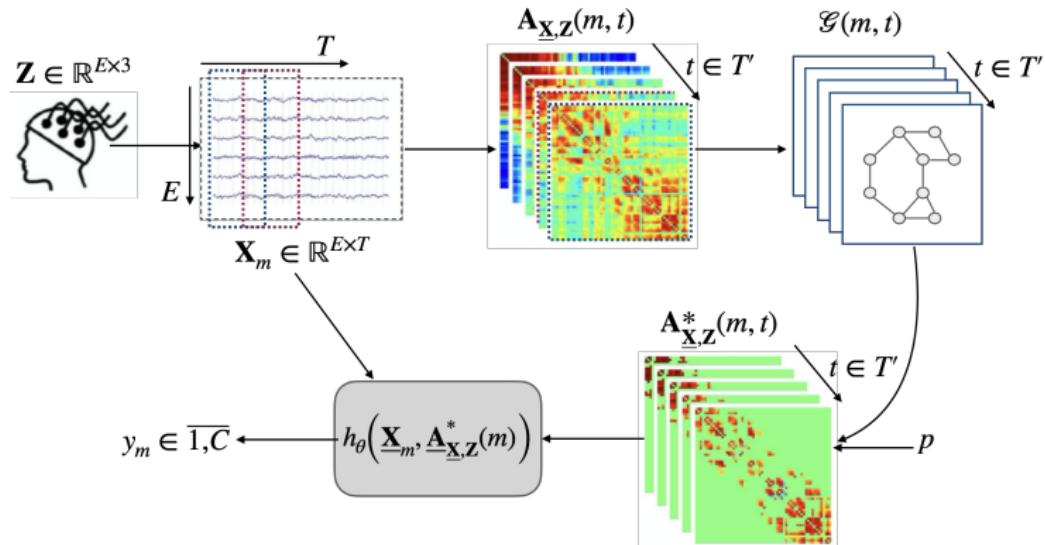
где

$$p_m^c = h_\theta \left(\mathbf{X}_m, \mathbf{A}_{\underline{\mathbf{X}}, \mathbf{Z}}(m, t) \right)$$

вероятность класса c для \mathbf{X}_m с матрицей $\mathbf{A}_{\underline{\mathbf{X}}, \mathbf{Z}}(m)$

Требуется найти оптимальные параметры $\theta^* = \theta^*(\underline{\mathbf{X}}, \mathbf{A}_{\underline{\mathbf{X}}, \mathbf{Z}})$ параметрического семейства функций $h(\cdot | \theta)$, минимизирующие функцию ошибки на обучающей выборке.

Предыдущие результаты: решение задачи классификации сигналов EEG с помощью GCN



Пайплайн предложенной модели: 1) пространственная структура многомерного временного ряда описывается графом; 2) композиция графовой свёрточной сети и рекуррентной сети преобразует последовательность графовых представлений сигнала в классификационную метку.

Предыдущие результаты: Модель GCN LSTM

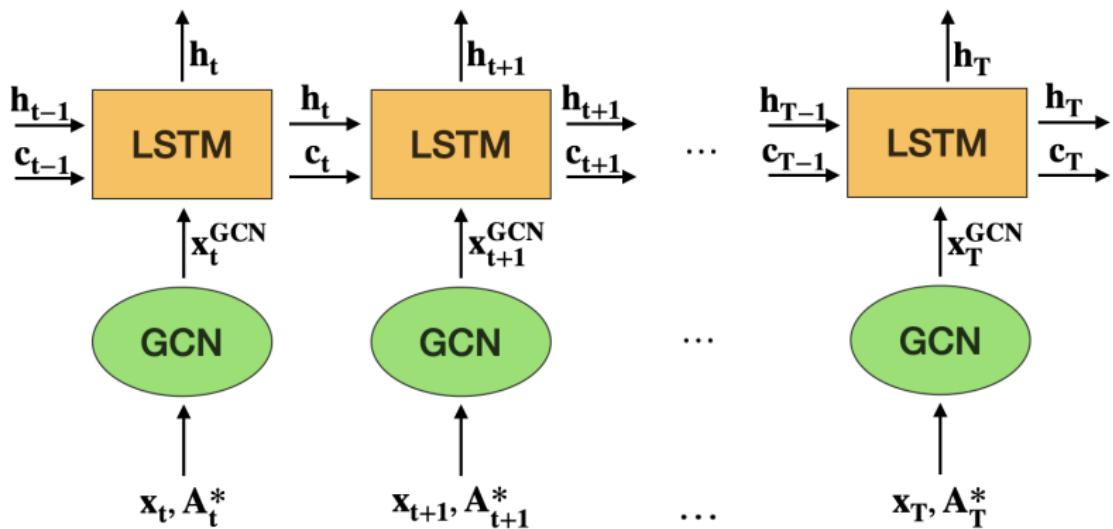


Схема использованной нейросети

Различные подходы к задаче декодирования многомерных временных рядов с помощью графовых нейросетей

Классификация пространственно-временных архитектур:

1. **Space-Then-Time (STT)**: сначала в каждый момент времени пространственная структура многомерного ряда агрегируется с помощью графовой нейросети, затем последовательность выходов этой сети подаётся на вход рекуррентной сети, отвечающей за временные зависимости компонент ряда.
2. **Time-Then-Space (TTS)**: наоборот, сперва ряд агрегируется по времени, а затем по пространству с помощью графовой сети.
3. **Time-and-Space (T&S)**: пространственно-временные зависимости многомерного временного ряда моделируются совместным образом.

1. Евклидово расстояние между электродами
2. Корреляция Пирсона между сигналами электродов
3. Спектральная когерентность
4. Частично направленная когерентность
5. Мера синхронизации фаз

Задача: По данным ЭЭГ выделить функциональные группы мозга, то есть решить задачу многоклассовой классификации.

Проблема: Из-за отсутствия регулярности структуры сигнала на сферической поверхности мозга CNN не могут быть эффективно применены для учета пространственной информации.

Предлагается: Рассмотреть графовое представление сигналов для учета функциональных взаимосвязей различных частей мозга в пространстве. Эти графовые представления предлагается использовать в качестве входов *диффузной графовой сети*.

Уравнение диффузии

Пусть $x(u, t)$ – величина потока (тепла) в среде в точке пространства u в момент времени t . Тогда уравнение диффузии имеет вид:

$$\frac{\partial x(u, t)}{\partial t} = \operatorname{div}[g(u, t, x(u, t)) \nabla_u x]$$

Дискретизация этого уравнения на графе имеет вид:

$$\frac{\partial}{\partial t} \mathbf{x}(t) = \dots = \mathbf{A}(\mathbf{x}(t)) \mathbf{x}(t)$$

Неявная схема Эйлера, шаги схемы соответствуют слоям графовой сверточной нейросети:

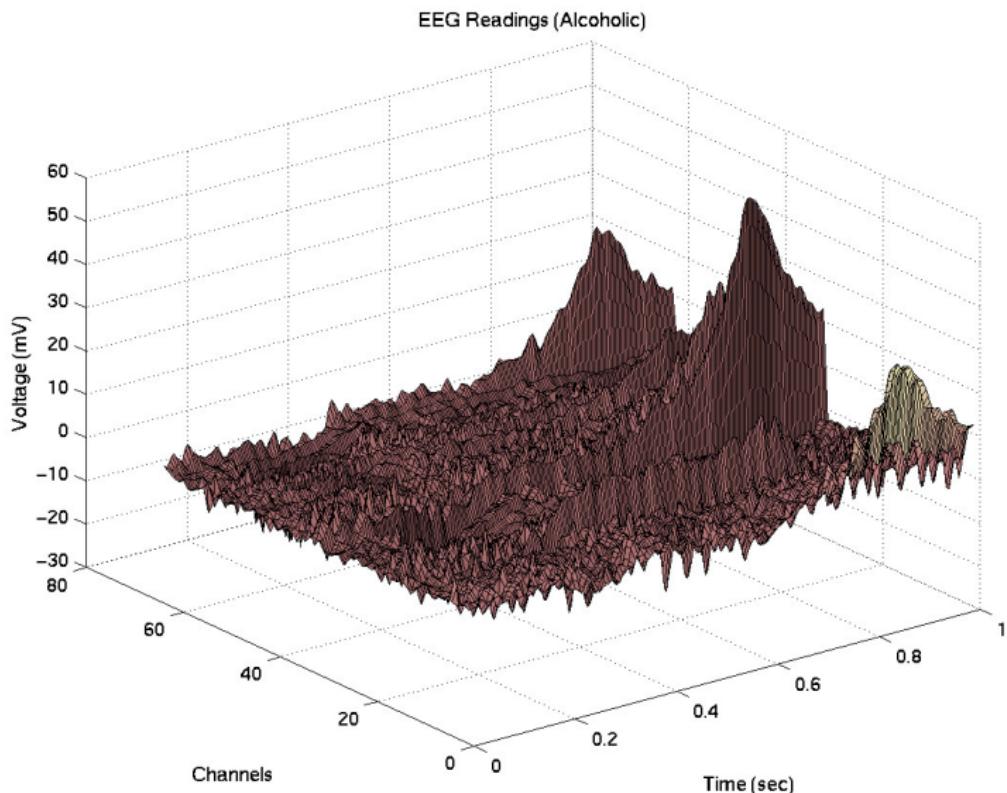
$$\frac{\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}}{\tau} = \mathbf{A}(\mathbf{x}^{(k)}) \mathbf{x}^{(k+1)} \rightarrow (\mathbf{I} - \tau \mathbf{A}(\mathbf{x}^{(k)})) \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)}$$

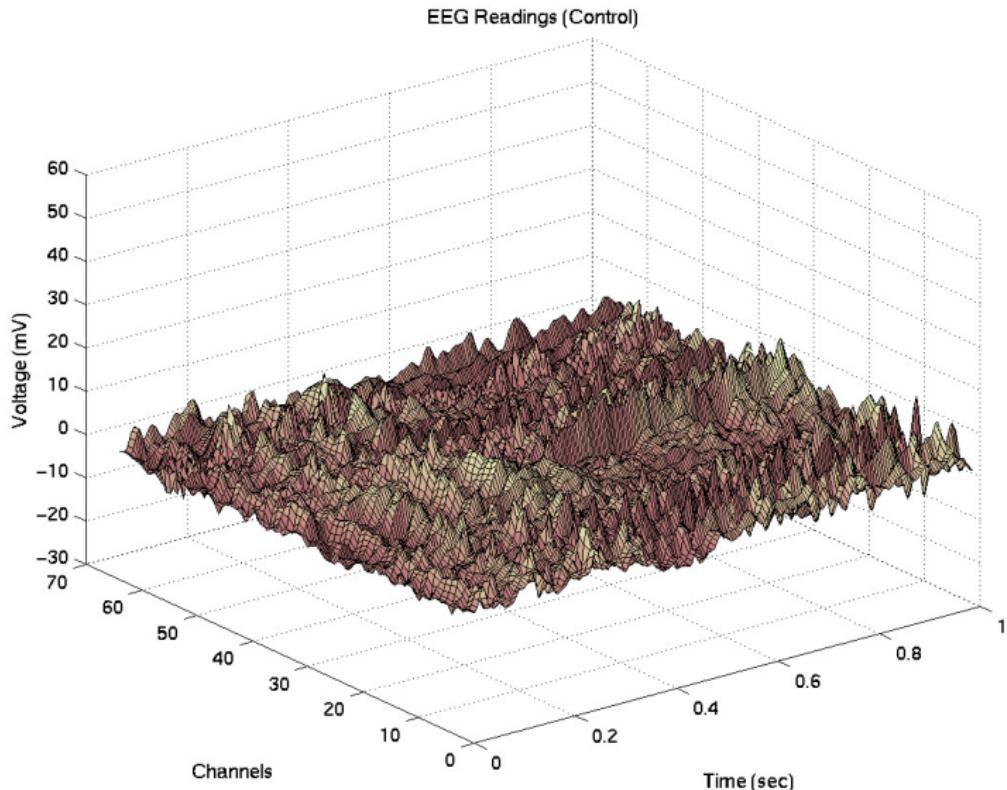
Гипотеза: Использование диффузной графовой нейросети позволяет повысить качество решаемой задачи и сократить ее размерность

Цели:

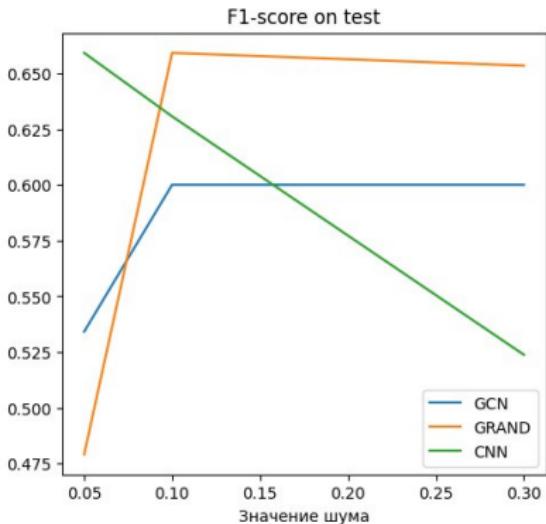
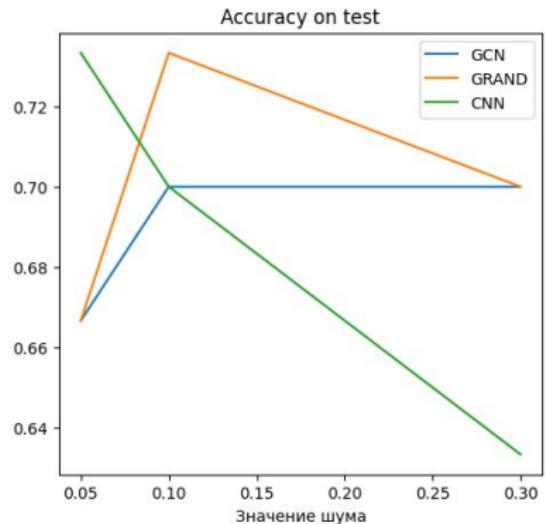
1. Обучить диффузную графовую нейросеть (в варианте GRAND).
2. Оценить качество работы полученной пространственно-временной модели.
3. Сравнить полученные результаты с существующими методами.

Данные: ЭЭГ исследования здоровых людей и людей больных алкоголизмом. Измерения проведены в 1999 году в процессе исследования корреляции между алкоголизмом и показателями ЭЭГ.

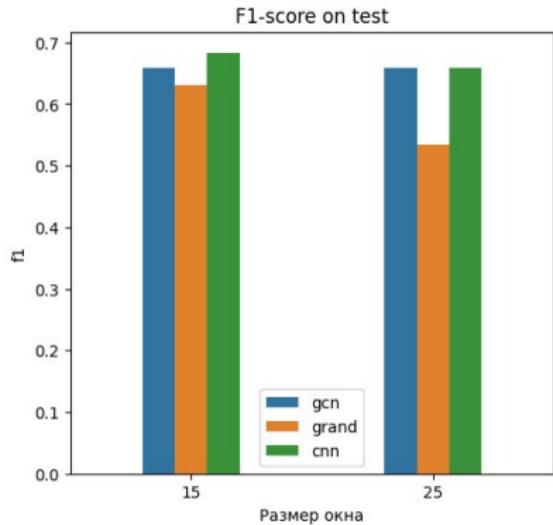
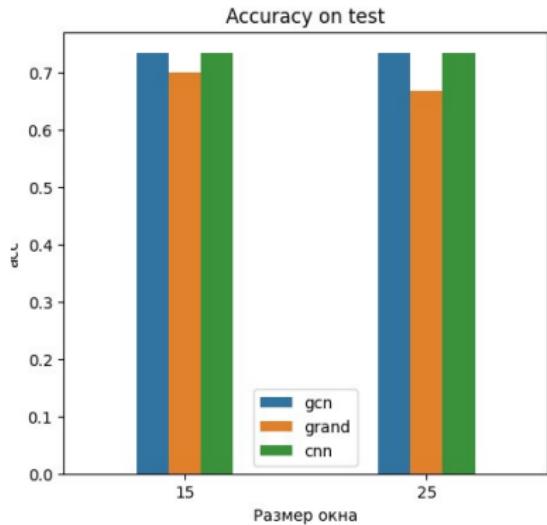




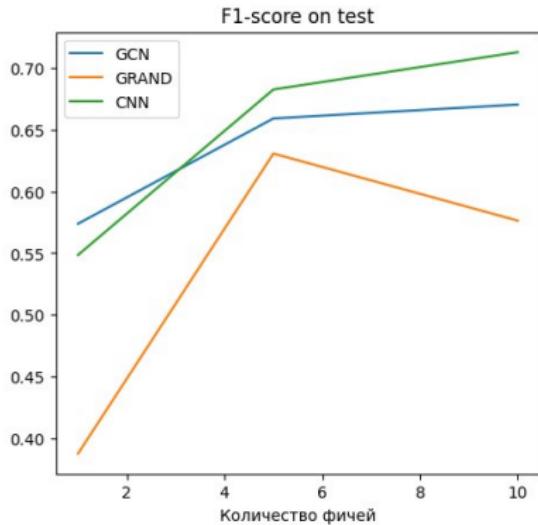
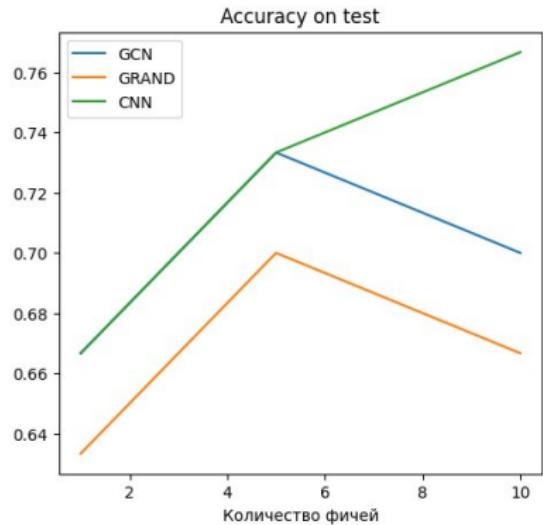
Результаты эксперимента



Результаты эксперимента



Результаты эксперимента



1. В эксперименте по нахождению оптимальной ширины окна показатели качества, полученные с помощью GCN, остаются практически неизменными, в то время как GRAND показывает в среднем более низкую точность и сильнее зависит от выбора T .
2. В эксперименте с добавлением шума GRAND показывает хорошее качество с увеличением дисперсии, а то время как accuracy и f -мера, полученные с помощью GCN, ожидаемо, падают. Это показывает потенциальную устойчивость модели GRAND к шуму за счет использования меньшего числа параметров.
3. Предполагается, что такие результаты могут быть обусловлены недообучением GRAND-а, связанного с сложностью переносимости кода с одной системы на другую и использованием CPU, а не GPU.

1. Предложена графовая диффузная нейросеть для решения задачи восстановления функциональных групп головного мозга.
2. Проанализирован ближайший конкурент модели GRAND-а - сверточные нейронные сети.
3. Не показано превосходство диффузной графовой нейросети по сравнению с графовыми сверточными сетями при меньшем числе параметров.
4. Продемонстрирована большая устойчивость GRAND-а к зашумленности данных по сравнению с сверточными нейронными сетями.